

TRABAJO FIN DE GRADO

GRADO EN INTELIGENCIA Y ANALÍTICA DE NEGOCIOS

ANÁLISIS COMPARATIVO DE MODELOS CLÁSICOS Y AVANZADOS EN LA GESTIÓN DE CARTERAS

ALUMNO/A:	Alejandro Moreno Sapena
TUTOR/A:	José Emilio Farinós Viñas
DEPARTAMENTO DEL TUTOR:	Finanzas empresariales
CURSO ACADÉMICO:	2024-2025
FECHA DE DEPÓSITO:	16/06/2025



Resumen

El presente trabajo se basa en un estudio comparativo entre dos enfoques diferentes de gestión de carteras: el modelo clásico de Markowitz y un modelo avanzado que emplea algoritmos genéticos. El objetivo principal es destacar las diferencias entre ambos modelos en términos de rentabilidad y riesgo, cuando son sometidos a escenarios diversos de mercado. A lo largo del análisis observaremos la manera en la que los modelos son capaces de adaptarse a situaciones de mayor y menor estabilidad, mostrando así, las ventajas y desventajas de ambos, según el tipo de escenario al que se enfrenten. Esta comparación nos dará una idea de la utilidad de ambos modelos en escenarios realistas, donde los mercados están en constante cambio.

Palabras clave

Gestión de carteras, Modelo clásico, Modelo avanzado, Rentabilidad, Riesgo, Escenarios.

Declaración de responsabilidad y autoría

D/Dª.: Alejandro Moreno Sapena, con
DNI 54488908E, estudiante del Grado_
Inteligencia y Analítica de Negocios, de la Universitat de València, realizado en
el/los curso/s 2021-2025.

DECLARO QUE:

El Trabajo Fin de Grado con título,

ANÁLISIS COMPARATIVO DE MODELOS CLÁSICOS Y AVANZADOS EN LA GESTIÓN
DE CARTERAS

ha sido desarrollado sin falsedades ni plagio, respetando la propiedad intelectual, citando las fuentes bibliográficas y/o documentales utilizadas en la redacción de dicho trabajo, así como cualquier otro derecho, por ejemplo el de imagen, que pudiese estar sujeto a protección del *copyright*. Asimismo, en el caso de haberla utilizado, se ha hecho un uso ético y como es debido de la IA, se ha referenciado adecuadamente y se ha informado de ello y en tiempo a su tutor/a.

En virtud de esta declaración afirmo que este trabajo es inédito, original y de mi autoría, por lo que me responsabilizo del contenido, veracidad y alcance del TFG y asumo las consecuencias administrativas y jurídicas que se deriven en caso de incumplimiento de esta declaración.

Y para que así conste, firmo la presente declaración en Valencia, a 11 de 06 de 2025.

Alejandro

Fdo.:

Índice

1. Introducción	6
2. Gestión de carteras clásica	7
2.1. Conceptos clave	7
2.2. Modelo Media-Varianza de Markowitz	10
2.2.1. Hipótesis	11
2.2.2. Etapas del modelo de Markowitz	12
2.3. Desventajas del modelo clásico	16
3. Gestión de carteras avanzada.....	17
3.1. Introducción a la optimización multiobjetivo	17
3.1.1. El concepto de la dominancia.....	18
3.1.2. Frontera Pareto.....	19
3.2. Algoritmos genéticos	20
3.2.1. Transfiriendo la evolución a los problemas de optimización	20
3.2.2. Esquema general.....	21
3.2.3. Proceso detallado	22
4. Estado del arte	23
5. Metodología.....	25
5.1. Objetivo metodológico	25
5.2. Modelo de investigación	26
5.3. Descripción del conjunto de datos	26
5.4. Software y herramientas	27
5.5. Diseño de los modelos	28
5.6. Medidas de Evaluación	29
5.7. Límites y posibles líneas de mejora	30
6. Discusión de resultados	31
6.1. Análisis <i>in-sample</i>	31
6.2. Análisis <i>out-of-sample</i>	35
6.3. Análisis en escenario de crisis	38
6.4. Análisis en escenario de recuperación de una crisis	40
7. Conclusiones	42
8. Bibliografía	45
9. Anexos	47

Índice de Figuras

Figura 1. Frontera eficiente	14
Figura 2. Curvas de indiferencia del inversor	15
Figura 3. Determinación de la cartera eficiente	15
Figura 4. Dominancia.....	19
Figura 5. Frontera Pareto	19
Figura 6. Algoritmo genético	21
Figura 7. Representación de las carteras sobre la frontera eficiente.....	34
Figura 8. Evolución de la rentabilidad de las carteras y del mercado en 2015.....	35
Figura 9. Análisis de la distribución de rentabilidades de la cartera ofrecida por el modelo Markowitz en 2015.....	37
Figura 10. Evolución de la rentabilidad de las carteras y del mercado en la crisis del COVID-19.....	38
Figura 11. Evolución de la rentabilidad de las carteras y del mercado en época de recuperación	40

Índice de Tablas

Tabla 1. Asignación de pesos del modelo Markowitz.....	31
Tabla 2. Evaluación in-sample de la cartera ofrecida por el modelo Markowitz	32
Tabla 3. Asignación de pesos del algoritmo genético multiobjetivo.....	32
Tabla 4. Evaluación in-sample de la cartera ofrecida por el algoritmo genético multiobjetivo .	33
Tabla 5. Comparación de los resultados out-of-sample	36
Tabla 6. Comparación de los resultados en el COVID-19.....	39
Tabla 7. Comparación de resultados en época de recuperación	41

1. Introducción

La gestión de carteras es, hoy en día, uno de los problemas principales en el área de las finanzas. Esta estrategia consiste en seleccionar una combinación específica de activos que ofrezca la mejor relación posible entre rentabilidad y riesgo.

Desde el siglo XX, el modelo de media-varianza, fundado por Markowitz, ha sido el enfoque más empleado para resolver este problema. No obstante, este modelo parte de unas hipótesis idealizadas, que imposibilitan que el modelo se adapte correctamente a entornos cambiantes. El problema principal de esto es que, en la mayoría de los casos, los mercados reales no son ideales, lo que conlleva a que el modelo clásico tenga dificultades para afrontar las condiciones reales de los mercados financieros de hoy en día.

Ante estas limitaciones, en los recientes años, han aparecido nuevos modelos alternativos, más flexibles, que utilizan herramientas de optimización más modernas, entre los cuales destacan los algoritmos genéticos. Estos algoritmos, se basan en los principios de la evolución natural y permiten abordar problemas de mayor complejidad, en los que intervienen múltiples criterios, restricciones no lineales y estructuras de soluciones que son difíciles de explorar con los métodos más clásicos.

Los algoritmos genéticos tienen la capacidad de generar soluciones muy diversas y adaptables, lo que los convierte en una opción prometedora para los contextos financieros basados en la incertidumbre, volatilidad y restricciones realistas.

Este Trabajo de Fin de Grado, tiene cuatro objetivos principales:

- 1- Presentar el funcionamiento general del modelo clásico de gestión de carteras de Markowitz.
- 2- Introducir el enfoque evolutivo de los algoritmos genéticos aplicado al problema de gestión de carteras.
- 3- Realizar un análisis comparativo bajo criterios de rentabilidad y riesgo.
- 4- Evaluar las ventajas y desventajas de ambos modelos en diferentes escenarios de mercado.

La cuestión que se plantea en este trabajo es:

¿Son los algoritmos genéticos más eficientes que el modelo clásico de Markowitz, cuando se aplica en entornos financieros realistas?

La hipótesis de partida es que, los algoritmos genéticos, al ser más flexibles y al poder emplear técnicas más avanzadas, permiten ofrecer carteras más estables y responder ante las adversidades de los mercados, pudiendo adaptarse mejor a escenarios inciertos.

Por último, cabe destacar que este trabajo seguirá la siguiente estructura:

En la primera parte, se presentará el marco teórico, donde se explicarán los fundamentos teóricos y algunas ventajas y desventajas de los dos modelos a estudiar: El modelo de Markowitz, y el modelo basado en algoritmos genéticos multiobjetivo. En esta parte también se mostrarán investigaciones previas relacionadas con nuestro tema que nos ayuden a reforzar nuestra hipótesis.

En la segunda parte, se desarrollará la metodología, donde se detallarán los datos empleados, su procedencia y naturaleza. Además, se expondrán las diferentes herramientas y programas empleados para la obtención, procesamiento y análisis de los datos. También se definirá el modelo de investigación planteado y se describirán tanto los diseños específicos de ambos modelos de gestión de carteras, como las métricas de evaluación que se usarán para interpretar los resultados del análisis. En el último apartado de la metodología se presentarán las diferentes limitaciones que tiene nuestro proyecto y alguna recomendación para investigaciones futuras.

En la tercera parte, se discutirán los resultados obtenidos tras aplicar ambos modelos en cuatro escenarios de mercado distintos, lo que nos permitirá observar su comportamiento y eficacia bajo diferentes condiciones.

En último lugar, se recogerán las principales conclusiones extraídas a partir del previo estudio comparativo realizado.

2. Gestión de carteras clásica

2.1. Conceptos clave

Cartera de inversión

Una cartera de inversión es un conjunto de activos financieros que un inversor posee con el objetivo de generar rendimientos a lo largo del tiempo. Estos activos pueden ser bonos, acciones, fondos de inversión u otros instrumentos de índole financiera

Riesgo sistemático y riesgo no sistemático

En primer lugar, el riesgo sistemático, es el que afecta a todo el mercado o a un conjunto muy amplio de activos. Está asociado a factores macroeconómicos como los tipos de interés, la inflación o las crisis económicas.

En segundo lugar, el riesgo no sistemático, también conocido como riesgo específico o diversificable, es el riesgo, que se asocia a un activo o empresa en particular. Este riesgo se genera por factores internos como las decisiones de gestión, el lanzamiento de productos o problemas legales (Bailey, 1999).

Diversificación

La diversificación es uno de los principios de la gestión de carteras. Es una estrategia que se basa en combinar diversos activos financieros con el fin de reducir el riesgo no sistemático. Se asume, por tanto, que los activos no actúan de forma perfectamente sincronizada, es decir, si un activo sube, el otro podría bajar, pudiendo compensar las pérdidas de uno con las ganancias de otros.

Esta estrategia, como se ha mencionado, es capaz de manejar el riesgo no sistemático, gracias a que combina diferentes activos en una misma cartera, esto conlleva a que los eventos negativos individuales puedan compensarse entre sí (Marcus, 2014).

Es importante destacar que, incluso si los activos están positivamente correlacionados, es posible reducir el riesgo total de la cartera combinándolos (siempre que no estén perfectamente correlacionados).

Rentabilidad

La rentabilidad es la ganancia o pérdida obtenida por una inversión en un periodo concreto. Normalmente se expresa como un porcentaje del capital invertido. En el contexto financiero, se suele hablar de rentabilidad esperada, como medida de la rentabilidad promedio que un inversor espera obtener (Fabozzi, 2002).

Para obtener la rentabilidad esperada de la cartera:

En primer lugar, se define la rentabilidad como variable aleatoria, que representa el rendimiento de un activo financiero en un periodo determinado.

$$\widetilde{R}_t = \frac{\widetilde{P}_t + \widetilde{D}_t - P_{t-1}}{P_{t-1}} \quad (1)$$

Donde $\widetilde{P}_t$ representa el precio del activo en periodo t y $\widetilde{D}_t$ los flujos de caja inciertos que generará el activo en periodo t.

A partir de ahí, se calcula la rentabilidad de la cartera como la combinación ponderada de las rentabilidades de los activos que la componen.

$$\widetilde{R}_p = x_1 \widetilde{R}_1 + x_2 \widetilde{R}_2 + \dots + x_N \widetilde{R}_N \quad (2)$$

Donde x_i representa el peso del activo i en la cartera.

Finalmente, se obtiene la rentabilidad esperada de la cartera, que es la media ponderada de las rentabilidades esperadas de cada activo.

$$E(\widetilde{R}_p) = x_1 E(\widetilde{R}_1) + \dots + x_N E(\widetilde{R}_N) \quad (3)$$

Volatilidad

La volatilidad es una medida de riesgo asociada a las rentabilidades de un activo financiero. Se expresa como la desviación típica de las rentabilidades respecto a su media. Cuando mayor es la volatilidad, mayor es la variabilidad de rentabilidades y, por tanto, mayor es el riesgo asumido.

$$\sigma_p = \sqrt{\sigma_p^2} \quad (4)$$

Siendo:

$$\sigma_p^2 = \sum_{i=1}^n x_i \left(\sum_{j=1}^n \text{Cov}(R_i, R_j) x_j \right) \quad (5)$$

Donde $\text{Cov}(R_i, R_j)$ representa la covarianza entre la rentabilidad de los activos i y j.

Utilidad

La utilidad es una medida del nivel de satisfacción o bienestar que un individuo asocia con una determinada opción, como una inversión. En finanzas, se utiliza para modelar las preferencias del inversor bajo condiciones de incertidumbre, y se asume que los inversores eligen entre alternativas que maximizan su utilidad esperada. En el contexto de la gestión de carteras, esto se traduce en la preferencia por combinaciones de activos con mayor rentabilidad esperada y menor riesgo.

La curva de isoutilidad, o curva de indiferencia, es un concepto de la teoría de la utilidad, que se aplica en economía y finanzas para representar las preferencias del inversor entre diferentes combinaciones de riesgo y rentabilidad (Sarnat, 1994).

2.2. Modelo Media-Varianza de Markowitz

Antes de la teoría de Markowitz, las estrategias de inversión se centraban en la selección individual de activos, sin una noción formal de “cartera”. El objetivo era identificar un activo “ganador”, generalmente basándose en su reputación, en noticias del mercado o en intuiciones personales, sin considerar de forma explícita el riesgo asociado.

La diversificación, aunque presente, era de carácter intuitivo y subjetivo. Se distribuían los fondos entre varios activos simplemente para evitar concentrar todo el riesgo en uno solo, pero sin herramientas cuantitativas que justificaran cómo hacerlo de forma óptima.

Este paradigma cambió radicalmente en 1952, cuando Harry Markowitz publicó su artículo “*Portfolio Selection*” en *The Journal of Finance*. Esta publicación supuso el nacimiento de la teoría moderna de carteras (Modern Portfolio Theory, MPT), al introducir un enfoque cuantitativo que evaluaba la rentabilidad esperada y el riesgo conjunto de toda la cartera, teniendo en cuenta la covarianza entre los activos.

Como explica Lo (2024), este estudio “cambió para siempre la forma en que los inversores piensan sobre el riesgo y el rendimiento dentro de una cartera”. Marcó una transición desde una perspectiva centrada en activos individuales a una visión global de todas las oportunidades de inversión, en la que se optimiza la asignación de pesos entre los activos según criterios matemáticos rigurosos. Esta nueva forma de entender la inversión sentó las bases de la gestión financiera moderna.

2.2.1. Hipótesis

La teoría moderna de carteras parte de una serie de hipótesis fundamentales que permiten su formulación matemática y su aplicación teórica. Estas hipótesis definen tanto el comportamiento esperado de los inversores como las características del mercado y de los activos financieros (Goetzmann 2014).

Hipótesis con respecto al comportamiento del inversor:

- El inversor toma sus propias decisiones en función de la rentabilidad esperada y el riesgo medido por la varianza:

$$U = U(\mu_p, \sigma_p^2) \quad (6)$$

- El inversor es racional, a mayor rentabilidad mayor utilidad:

$$\frac{\partial U}{\partial \mu_p} > 0 \quad (7)$$

- El inversor es averso al riesgo, a menor riesgo mayor utilidad:

$$\frac{\partial U}{\partial \sigma_p^2} < 0 \quad (8)$$

- Las curvas de indiferencia del inversor son crecientes y cóncavas.
- El horizonte temporal es uniperiodal, por lo que se asume que todas las decisiones de inversión se toman al inicio de un único periodo, y que los rendimientos de los activos se observan al final de este. No se contempla la evolución intermedia ni la posibilidad de rebalancear la cartera en el transcurso del tiempo.

Hipótesis con respecto a los activos:

- Se asumen N activos financieros arriesgados (cotizan en mercados bursátiles).

-Las características relevantes de los activos y de las carteras son su rentabilidad esperada (esperanza matemática) y su riesgo (medido mediante varianza o desviación típica).

-Se supone que la distribución de probabilidad de la rentabilidad de cada activo es conocida por el inversor y que los rendimientos siguen una distribución normal, lo que permite representar el riesgo únicamente mediante la varianza.

Hipótesis con respecto a los mercados financieros:

Los mercados financieros se asumen perfectos, lo que implica, entre otras condiciones, la ausencia de costes de transacción, impuestos e inflación, así como la existencia de información completa y simétrica entre los agentes económicos (Hernández, 2022).

2.2.2. Etapas del modelo de Markowitz

El modelo planteado por Markowitz pretende determinar la cartera óptima, es decir, aquella que maximice la utilidad esperada por el inversor (Hernández, 2022). Para ello determina un proceso de cuatro etapas que consiste en:

a) Determinar el conjunto de posibilidades de inversión

En esta etapa se parte de un conjunto de N activos financieros arriesgados y se analizan todas las combinaciones posibles entre ellos. Para ello, se estima la rentabilidad esperada, la varianza de cada activo y la covarianza entre pares de activos.

Cuando se combinan dos activos con correlación intermedia, las posibles carteras forman una curva en forma de hipérbola, más curvada cuanto menor es la correlación. Con N activos, las combinaciones posibles generan una región de carteras llamada conjunto viable, que representa todas las combinaciones de riesgo y rentabilidad posibles sin restricciones (Marcus, 2014).

b) Determinar la frontera eficiente

Una cartera eficiente se obtiene resolviendo un problema de programación cuadrática paramétrica que se puede plantear de dos formas (Goetzmann, 2014):

- Para un nivel dado de riesgo, no existe otra cartera con mayor rentabilidad esperada.

$$\begin{aligned}
& \text{Max } \mu_p \\
& \sigma_p^2 \leq V \\
& \sum_{i=1}^n w_i = 1; \quad w_i \geq 0 \quad (i = 1, \dots, n)
\end{aligned} \tag{9}$$

Donde V es un parámetro del riesgo que decide el inversor.

- Para un nivel dado de rentabilidad, no existe otra cartera con menor riesgo.


$$\begin{aligned}
& \text{Min } \sigma_p^2 \\
& \mu_p \geq r \\
& \sum_{i=1}^n w_i = 1; \quad w_i \geq 0 \quad (i = 1, \dots, n)
\end{aligned} \tag{10}$$

Donde r es un parámetro de la rentabilidad que decide el inversor.

Este último programa genera el conjunto de carteras de mínima varianza.

Esto significa que una cartera eficiente representa el mejor equilibrio posible entre riesgo y rentabilidad. Dentro del Modelo de Markowitz, el conjunto de todas estas carteras eficientes forma lo que se conoce como la frontera eficiente. En la siguiente imagen se puede observar una representación de la frontera eficiente.

Figura 1. Frontera eficiente



Fuente: Figura de López, (2020).

La curva que aparece en la imagen muestra todas las combinaciones eficientes: desde carteras de bajo riesgo y menor rentabilidad hasta carteras de alto riesgo y mayor rentabilidad.


La cartera eficiente con menor riesgo es conocida como la cartera de mínima varianza global (CMVG), y es el punto de partida de la frontera eficiente. Cualquier cartera que esté por debajo o a la derecha de esta curva se considera ineficiente, ya que existe otra combinación que mejora el riesgo o el retorno.

c) Especificar las preferencias del inversor

En esta etapa intervienen las curvas de indiferencia que, como se menciona en el apartado de hipótesis, son crecientes y convexas. La forma específica dependerá del grado de aversión al riesgo del inversor.

Una curva de indiferencia o isoutilidad es la representación gráfica de todas las combinaciones rendimiento esperado-riesgo que proporcionan al inversor la misma utilidad esperada y que le son indiferentes, en la Figura 2 están representadas estas curvas.

Figura 2. Curvas de indiferencia del inversor



Fuente: Figura de López (2020).


Se puede observar que a medida que nos desplazamos hacia el norte en el mapa de curvas de isoutilidad, se incrementa el índice de utilidad de las mismas.

d) Determinar la cartera óptima

La cartera óptima de un inversor la determina el punto tangente entre una de las curvas de indiferencia del inversor y la frontera eficiente. Las curvas que están por debajo de ese punto darán menos satisfacción y las que están por encima de ese punto no son factibles. Así se observa en la Figura 3.

Figura 3. Determinación de la cartera eficiente

i.



Fuente: Figura de López (2020).

2.3. Desventajas del modelo clásico

Supuestos poco realistas del modelo

El modelo de Markowitz parte de hipótesis simplificadas que no se ajustan a la realidad de los mercados financieros. Por ejemplo, Guo (2022) señala que asume mercados plenamente eficientes, cuando en la práctica estos son ineficientes y están influenciados por factores conductuales: *“the model is based on the premise that financial markets should be strong form efficient”*.

Inadecuación ante datos no normalmente distribuidos

Según Guo (2022), una de las principales limitaciones técnicas del modelo es su dependencia de la normalidad en la distribución de los rendimientos. Esto compromete la validez del análisis en entornos reales, donde los rendimientos financieros suelen mostrar asimetría y colas pesadas.

Desventajas del uso de la varianza como medida de riesgo

Satchell (2010) critica el uso exclusivo de la varianza para medir el riesgo, ya que esta no diferencia entre desviaciones positivas (ganancias) y negativas (pérdidas). Esto implica que la incertidumbre ante rendimientos positivos se penaliza igual que ante rendimientos negativos.

Alta sensibilidad a errores de estimación

Otra crítica importante al modelo es su elevada sensibilidad a errores en los parámetros estimados, especialmente en las medias, varianzas y covarianzas. Satchell (2010) advierten que estos errores pueden derivar en carteras subóptimas.

Complejidad computacional ante restricciones realistas

Varios autores han señalado que la inclusión de restricciones prácticas, como límites de cardinalidad o sectores, transforma el problema clásico de optimización en uno mucho más complejo. En concreto, Bienstock (1996) y Jobst (2001) explican que *“the addition of cardinality constraints transforms the problem into a mixed-integer quadratic program (MIQP), which is NP-hard”*, lo cual incrementa la carga computacional de forma significativa.

Fragmentación del espacio de soluciones y óptimos locales

Mamanis (2011) destaca que al incluir múltiples restricciones simultáneamente, el espacio de soluciones se fragmenta y el modelo puede quedarse atrapado en óptimos

locales, sin alcanzar la mejor solución global. Esto limita la eficacia del modelo en contextos reales donde se imponen múltiples condiciones prácticas a la inversión.

3. Gestión de carteras avanzada

La gestión de carteras tiene como objetivo combinar activos financieros de forma que se alcance un equilibrio óptimo entre rentabilidad y riesgo. Aunque el modelo de Markowitz proporcionó los fundamentos teóricos mediante un enfoque matemático riguroso, su aplicación práctica se enfrenta a condiciones mucho más complejas, que exigen métodos de mayor flexibilidad.

En este contexto, la gestión de carteras avanzada incorpora técnicas capaces de contemplar restricciones realistas, criterios de optimización alternativos y herramientas computacionales más sofisticadas, como los algoritmos evolutivos. Estas metodologías permiten diseñar carteras que se ajusten mejor a los objetivos, preferencias y limitaciones de los inversores, especialmente en entornos caracterizados por la incertidumbre y la dinámica cambiante de los mercados financieros (Schmeck, 2009).

3.1. Introducción a la optimización multiobjetivo

La programación multiobjetivo, también conocida como optimización multiobjetivo u optimización multicriterio, es una rama del análisis de la decisión multicriterio. Esta disciplina utiliza técnicas cuantitativas para seleccionar una o varias alternativas (soluciones) cuando existen múltiples criterios o funciones objetivo que deben ser considerados simultáneamente (Deb., 2001).

Denotemos S como al conjunto de soluciones factibles, es decir, aquellas que cumplen todas las restricciones del problema. Llamemos P a una solución, donde $P \in R^n$ y se expresa como un vector de decisiones $P = (x_1, x_2, \dots, x_n)$. La imagen de P en el espacio de objetivos se define como:

$$F(P) = (f_1(P), f_2(P), \dots, f_k(P)) \quad (11)$$

donde cada $f_i(P)$ representa una función objetivo a maximizar o minimizar.

Optimización con un objetivo

$$\text{Maximizar } f(P) \text{ s.a. } P \in S \quad (12)$$

Una solución óptima es aquella solución factible cuyo valor de la función objetivo no puede ser superado por ninguna otra solución factible. Puede haber múltiples soluciones óptimas si diferentes decisiones conducen al mismo valor objetivo.

Optimización multiobjetivo

$$\text{Maximizar } F(P) = (f_1(P), f_2(P), \dots, f_k(P)) \text{ s.a. } P \in S \quad (13)$$

En este caso, surgen dos cuestiones clave: ¿Qué entendemos por solución óptima?
¿Con qué solución debemos quedarnos cuando existen múltiples criterios en conflicto?


3.1.1. El concepto de la dominancia

Se dice que un vector a domina a otro b si (suponiendo maximización):

$$\forall i \in \{1, 2, \dots, K\} \mid f_i(a) \geq f_i(b) \wedge \exists j \in \{1, 2, \dots, K\} \mid f_j(a) > f_j(b) \quad (14)$$

Este concepto queda claro en la Figura 4.

Figura 4. Dominancia




Fuente: Elaboración propia

En este ejemplo, A y C son no dominadas entre sí (ninguna domina a la otra). Las dos dominan a B (Rodríguez, 2020).

3.1.2. Frontera Pareto

La frontera de Pareto, o conjunto no dominado, es el conjunto de soluciones Pareto-óptimas. Una solución es Pareto-óptima si no existe otra solución que la domine (Sáez, 2023).

Figura 5. Frontera Pareto



Fuente: Figura de Sáez (2023).

Una vez que se ha obtenido la frontera Pareto, el tomador de decisiones necesita seleccionar una única solución (una cartera específica) de este conjunto. Esta elección se basa en un criterio o preferencia particular.

3.2. Algoritmos genéticos

En los años 1970, de la mano de Holland, surgió una de las líneas más prometedoras de la inteligencia artificial, la de los algoritmos genéticos. Son llamados así porque se inspiran en la evolución biológica y su base genético-molecular.

Estos algoritmos hacen evolucionar una población de individuos sometiéndola a acciones aleatorias (semejantes a las que actúan en la evolución biológica, como las mutaciones) y a una selección. De acuerdo con algún criterio que decide el investigador, sobreviven los individuos que mejor se adaptan y se descarta al resto.

Los algoritmos genéticos se enmarcan dentro de los algoritmos evolutivos, que incluyen también las estrategias evolutivas, la programación evolutiva y la programación genética.

3.2.1. Transfiriendo la evolución a los problemas de optimización

En los algoritmos genéticos, diversos conceptos biológicos son reinterpretados para modelar el proceso de búsqueda y optimización (Mitchell 1998).

Cromosomas

Representan la codificación de una solución dentro del espacio de búsqueda del problema.

Población

Corresponde al conjunto de soluciones candidatas que evolucionan generación tras generación.

Fitness o calidad del cromosoma

Está determinada por la función objetivo, que evalúa el desempeño de cada solución.

Selección de los mejores individuos

Simula un mecanismo de supervivencia, en el que las soluciones con mayor *fitness* tienen más probabilidades de ser seleccionadas para reproducirse.

Cruce y mutación

Son los operadores genéticos que permiten recombinar y modificar las codificaciones de las soluciones para generar nuevas alternativas potencialmente mejores.


Elitismo

Este mecanismo asegura que las mejores soluciones se mantengan en la siguiente generación. En la naturaleza, los individuos "más aptos" tienden a vivir más y reproducirse con mayor éxito. De forma análoga, los algoritmos genéticos con alto grado de elitismo conservan una proporción significativa de las mejores soluciones, reduciendo el riesgo de pérdida de información valiosa y acelerando la convergencia del algoritmo.

3.2.2. Esquema general

- 1- Generar población inicial P de tamaño N.
- 2- Mientras no se cumpla un criterio de parada:
 - 2.1- Generar H, población de hijas, mediante operadores de cruce y mutación.
 - 2.2- Calcular la nueva población P a partir de la antigua población P y H.
- 3- Ofrecer la mejor solución y su función objetivo.

Figura 6. Algoritmo genético



Fuente: Figura de Ballestín (2023).

3.2.3. Proceso detallado

Los algoritmos genéticos funcionan gracias a 6 elementos clave (Mitchell, 1998).

Generar Población inicial

En los algoritmos genéticos, se generan soluciones factibles (completas y válidas) y se selecciona un subconjunto de tamaño N , que representa la población inicial. Este valor N es un parámetro clave, y su elección influye en el comportamiento del algoritmo. Un valor pequeño de N favorece una convergencia rápida, aunque con menor calidad en las soluciones, y suele requerir un alto grado de elitismo. Por el contrario, un N grande incrementa la diversidad y puede conducir a mejores soluciones, aunque con mayor coste computacional.

Las soluciones pueden generarse mediante métodos aleatorios o constructivos guiados, y es posible crear más soluciones de las necesarias y conservar sólo las mejores, reforzando así el elitismo. Si no se opta por ampliar la población, pueden emplearse otras estrategias para mantener la diversidad y la calidad del proceso evolutivo

Operador de cruce (*crossover*)

El operador de cruce se encarga de combinar la información genética de dos soluciones progenitoras para generar nuevas soluciones (descendencia). Este proceso, que simula la reproducción biológica, produce típicamente un hijo y una hija que heredan características de ambos padres. El cruce debe incorporar aleatoriedad para garantizar diversidad en la descendencia, incluso cuando se aplica varias veces a los mismos progenitores.

Normalmente se define una estrategia de cruce para un descendiente y se intercambian los roles parentales para generar el otro. En caso de que las soluciones generadas sean incompletas o infactibles, es necesario aplicar mecanismos de reparación, como la mutación u otras técnicas correctivas.

Operador de mutación

Consiste en modificar levemente una codificación (5-15%) y se lleva a cabo sin tener en cuenta la función objetivo. Se emplea para preservar la diversidad de las poblaciones y explorar nuevas zonas del espacio de soluciones.

- Si el problema tiene elementos no presentes en la codificación, la mutación tiene que dar posibilidades de que se incorporen.
- Si la solución resultante es infactible o incompleta, será necesario aplicar mecanismos para solucionarlo.

Creación de la población de hijos H

Se obtienen N hijos, para ello se escogen N/2 parejas y se seleccionan dos hijos de cada una. Esto se puede llevar a cabo de dos formas:

- Con más elitismo: una codificación puede ser escogida varias veces para reproducirse, y las soluciones con mejor función objetivo tienen más posibilidad de ser escogidos para ello.
- Sin elitismo: cada codificación se escoge una vez para reproducirse

Cálculo de la nueva población P

Se puede hacer de dos formas:

- Manera más elitista: juntar la población de padres y de hijos y escoger a los mejores.
- Manera mixta: escoger el 50% de la siguiente población escogiendo los mejores. Eliminar a esos escogidos y al restante 50% escogerlos aleatoriamente (o de manera que sean más diferentes, para aumentar diversidad)

Criterio de parada

Algunos criterios de parada son: Fijar un número máximo de soluciones generadas, fijar un número máximo de iteraciones sin mejorar la mejor solución, fijar una diversidad mínima en la población, o fijar un límite de tiempo.

4. Estado del arte

Numerosas investigaciones han comparado el desempeño de la optimización clásica de carteras con metodologías metaheurísticas (como AG) en distintos escenarios financieros, incluyendo mercados dinámicos o inciertos. En general, la evidencia sugiere que los enfoques evolutivos igualan o superan al modelo de Markowitz en contextos donde las premisas de éste se debilitan.

Un estudio reciente de Mwamba (2025) aplicó un algoritmo genético multiobjetivo avanzado (NSGA-III) para optimizar carteras considerando múltiples criterios. Sus hallazgos revelan que NSGA-III supera significativamente al método de Media-Varianza, al generar un conjunto más diverso de carteras Pareto-óptimas. Las carteras optimizadas con NSGA-III exhibieron un desempeño superior, logrando mayores ratios de Sharpe, sesgos más favorables y menor curtosis en las distribuciones de retorno, lo

que indica una mejor adaptación al perfil de riesgo-retorno deseado. En otras palabras, no solo se obtuvieron soluciones más variadas, sino también de mayor calidad financiera comparadas con la optimización tradicional.

De forma similar, Prasanna (2018) investigó la incorporación de momentos superiores de la distribución (asimetría y curtosis) en la selección de carteras. Incluir explícitamente el sesgo y la curtosis como parte del criterio de optimización hace que el problema se vuelva no convexo y multiobjetivo, una situación complicada para los métodos clásicos pero abordable mediante algoritmos genéticos. En su estudio, resolvieron el problema con un AG y hallaron que el modelo de cartera que considera los momentos superiores (optimizado vía AG) superó al modelo media-varianza tradicional a lo largo del periodo 2000–2012, especialmente en mercados emergentes. Esto refuerza la noción de que métodos evolutivos permiten capturar mejor las características reales de los retornos (que suelen desviarse de la normalidad) y traducirlas en carteras más eficientes.

Por otro lado, algunos trabajos han abordado la aplicación de algoritmos genéticos en la asignación estática de carteras incorporando medidas de riesgo basadas en el valor en riesgo histórico (VaR). En este tipo de enfoques, se plantean funciones de utilidad que integran métricas adicionales como el riesgo E-SV, permitiendo a los algoritmos genéticos encontrar soluciones óptimas o próximas al óptimo. Estos métodos ofrecen una alternativa eficaz frente a las limitaciones de los modelos tradicionales, especialmente en contextos donde la complejidad de la función objetivo dificulta la aplicación de técnicas clásicas de optimización.

También está el estudio Venegas-Flores, que aplicó un algoritmo genético clásico a una cartera de 10 empresas pertenecientes a los sectores de tecnología, salud y finanzas con datos comprensivos desde 2020 hasta 2023. El estudio demuestra que los algoritmos genéticos pueden generar soluciones diversificadas favoreciendo inversiones sostenibles, alineadas con los Objetivos de Desarrollo Sostenible de la ONU. El enfoque combina técnicas cuantitativas avanzadas con consideraciones éticas y medioambientales, mostrando que es posible desarrollar carteras robustas que integran retornos financieros y objetivos de sostenibilidad, incluso en entornos de alta volatilidad.

Más allá de estos trabajos, se han reportado ventajas de las metaheurísticas en casos de alta incertidumbre. Por ejemplo, en entornos con fuertes cambios estructurales, carteras obtenidas por algoritmos genéticos tienden a ser más estables out-of-sample que las derivadas de optimizaciones paramétricas clásicas, debido a que los AG pueden incorporar directamente simulaciones de escenarios extremos en la función objetivo

(robusteciendo la cartera contra ellos). También en problemas con restricciones de cardinalidad, estudios han demostrado que los algoritmos genéticos encuentran soluciones cercanas al óptimo de Markowitz, pero cumpliendo el límite en el número de activos, algo que la optimización cuadrática sola no logra manejar eficazmente.

5. Metodología

5.1. Objetivo metodológico

El objetivo metodológico de este proyecto es diseñar dos modelos de gestión de carteras y compararlos en diferentes escenarios.

En primer lugar, se mostrará el funcionamiento de ambos modelos empleando datos históricos de los precios en un año 'visto', será un análisis *in-sample*, con la finalidad de observar cómo optimiza cada modelo cuando tiene todos los datos a su disposición, algo ideal pero irrealista, pero servirá como punto de referencia para detectar posteriormente posibles problemas de sobreajuste en cada modelo.

En segundo lugar, se implementarán los mismos modelos sobre un año no 'visto', siendo previamente entrenados con datos históricos de los precios de años anteriores. En esta fase se detectan los problemas de sobreajuste de un modelo, si un modelo ofrecía muy buenos resultados sobre datos conocidos quizás es porque se estaba ajustando en exceso a esos datos, lo que puede provocar un descenso del rendimiento cuando se aplique a años desconocidos.

En tercer lugar, se realizará el mismo proceso que en la segunda implementación, pero sobre una época de crisis global.

En último lugar, se realizará el mismo proceso, pero empleando los años de crisis para entrenar los datos, de esta forma los modelos aprenden de unos datos con escenarios variados y subidas y bajadas más extremas. Después se aplicará sobre un año de recuperación de una crisis que empieza a estabilizarse. El objetivo de esto es evaluar si los modelos entrenados con contextos de alta volatilidad y cambios bruscos son capaces de adaptarse mejor a un entorno incierto, pero en recuperación.

5.2. Modelo de investigación

Este trabajo sigue un enfoque cuantitativo basado en el análisis de datos financieros extraídos de fuentes oficiales. El objetivo es comparar el rendimiento de dos modelos de optimización de carteras: el clásico de Markowitz y un algoritmo genético multiobjetivo.

Se evaluarán ambos enfoques en distintos contextos de mercado utilizando métricas cuantitativas que serán representadas en tablas y gráficos.

5.3. Descripción del conjunto de datos

En este trabajo se ha trabajado con precios históricos diarios de 10 empresas cotizadas en el IBEX 35, seleccionadas con la finalidad de representar a distintos sectores económicos y asegurando una muestra variada y diversificada que represente bien al resto de las empresas. Esta selección permite analizar cómo se comportan los modelos de optimización en un entorno que refleja diferentes niveles de riesgo, ciclos económicos y dinámicas de mercado.

Las empresas españolas elegidas pertenecen a sectores como:

- Financiero: Santander (SAN.MC), BBVA (BBVA.MC)
- Consumo discrecional: Inditex (ITX.MC)
- Energía: Iberdrola (IBE.MC), Repsol (REP.MC)
- Telecomunicaciones: Telefónica (TEF.MC)
- Construcción e infraestructuras: ACS (ACS.MC), Ferrovial (FER.MC)
- Salud: Grifols (GRF.MC)
- Tecnología: Amadeus (AMS.MC)

Los datos han sido extraídos mediante el paquete `yfinance` de Python, que permite acceder de forma automatizada y gratuita a los datos bursátiles ofrecidos por Yahoo Finance. Mediante este paquete se pueden obtener variables como: precios de apertura, precios de cierre, precios máximos, precios mínimos y volumen. En nuestra investigación solo nos centraremos en la variable de precios de cierre.

Se ha utilizado una frecuencia temporal diaria en los precios, ya que proporciona una mayor granularidad en la evolución de los precios y permite capturar mejor la volatilidad de los activos, así como la dinámica real de los mercados financieros. Esta elección es

especialmente útil en modelos de optimización que requieren una estimación precisa de los rendimientos y de la matriz de covarianzas, aspectos que se ven favorecidos por un mayor número de observaciones.

Para este estudio se han seleccionado distintos horizontes temporales con el objetivo de evaluar el comportamiento y la robustez de los modelos bajo contextos de mercado diversos, incluyendo tanto periodos estables como periodos de crisis y recuperación. En concreto, se han definido cuatro escenarios de análisis:

a) Análisis *in-sample* (2015)

Se ha entrenado y evaluado el modelo sobre el mismo año para observar su capacidad de ajuste dentro de un único entorno económico.

b) Análisis *out-of-sample* (entrenamiento con datos de 2012–2014 y test con datos de 2015)

Permite comprobar si los modelos contruidos con datos anteriores son capaces de generalizar adecuadamente y obtener buenos resultados en un año no visto.

c) Análisis en escenario de crisis (entrenamiento con datos de 2019 y test con datos de marzo–abril de 2020)

Se utiliza para analizar cómo se comportan las carteras optimizadas en un entorno inesperado de alta volatilidad, como el inicio de la crisis del COVID-19.

d) Análisis en escenario de recuperación de una crisis (entrenamiento con datos de 2018–2020 y test con datos de 2021)

Este enfoque busca evaluar la capacidad de los modelos para aprender de distintos escenarios (estabilidad, crisis y rebote) y aplicarlos a un año en el que el mercado comienza a estabilizarse.

5.4. Software y herramientas

Todo el análisis se ha realizado en Python, utilizando el entorno Jupyter Notebook por su facilidad para combinar código, resultados y explicación en un mismo documento.

Entre las principales librerías empleadas se encuentran:

- yfinance para descargar datos históricos,
- numpy y pandas para el tratamiento de datos,
- cvxpy para implementar el modelo de Markowitz,
- pymoo para desarrollar el algoritmo genético multiobjetivo.

- matplotlib para la visualización de resultados.

Antes de aplicar los modelos de optimización, se ha llevado a cabo un proceso de limpieza y transformación de los datos para garantizar la coherencia y calidad de los resultados.

En primer lugar, se han utilizado los precios de cierre ajustados (*adjusted close*), que corrigen los precios históricos por dividendos, *splits* y otros eventos corporativos. Este ajuste, que se realiza mediante una función integrada en el paquete *yfinance*, permite que los rendimientos reflejen de forma más realista el retorno total que habría recibido un inversor.

Posteriormente, se han eliminado las observaciones con valores nulos, que pueden aparecer por falta de cotización en días específicos o por errores en la fuente de datos.

A partir de los precios ajustados, se han calculado los rendimientos logarítmicos diarios, preferidos frente al simple porque permiten una mejor agregación temporal, facilitan los cálculos en modelos de optimización y son más coherente con retornos continuos.

Por último, se ha organizado la información de forma adecuada para poder aplicar los modelos, generando las matrices de rendimientos, varianzas y covarianzas, así como las funciones objetivo y restricciones necesarias para los distintos enfoques multiobjetivo.

5.5. Diseño de los modelos

Se han implementado dos modelos: un Markowitz clásico y un algoritmo genético multiobjetivo.

En el modelo de Markowitz, se impone una restricción de volatilidad máxima como parámetro de control del riesgo, mientras que la función objetivo consiste en maximizar el rendimiento esperado de la cartera.

Por otro lado, el algoritmo genético multiobjetivo también incorpora la misma restricción de volatilidad, con el fin de garantizar una comparación justa entre ambos modelos.

Es importante destacar que la restricción no es una igualdad en ninguno de los dos casos, no se está forzando un nivel exacto de volatilidad en los modelos, se está señalando cuál es el nivel máximo que no podrán superar.

Ambos modelos están diseñados para asegurar que la suma de los pesos de los activos en cartera sea igual a uno, garantizando así una asignación coherente de capital.

El modelo genético se optimiza simultáneamente en torno a cuatro objetivos:

- Maximizar el rendimiento esperado.
- Minimizar el CVaR al 95%.
- Minimizar la volatilidad.
- Minimizar la curtosis.

Este modelo se ejecuta con los siguientes parámetros evolutivos: una población de 100 individuos, 200 generaciones y una tasa de mutación del 10%.

Finalmente, de entre todas las soluciones obtenidas en la frontera de Pareto, se selecciona aquella con el mejor Sharpe Ratio, con el objetivo de facilitar la comparación con el modelo de Markowitz, que también optimiza este indicador de forma indirecta.

5.6. Medidas de Evaluación

Sharpe Ratio

Mide la rentabilidad ajustada al riesgo, comparando el exceso de retorno de la cartera sobre el activo libre de riesgo con su volatilidad.

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p} \quad (16)$$

donde R_f es la tasa libre de riesgo (0,03 en nuestro caso).

Conditional Value-at-Risk

Mide la pérdida esperada en el peor 5 % de los casos. Es una medida coherente de riesgo y captura mejor el riesgo de cola que el VaR.

$$\text{CVaR}_{95\%} = -\frac{1}{\alpha N} \sum_{i=1}^{\alpha N} r_i \quad (17)$$

Índice de Herfindahl-Hirschman

Mide la concentración de la cartera. Un valor más alto indica mayor concentración, mientras que uno más bajo indica mejor diversificación.

$$\text{HHI} = \sum_{i=1}^n w_i^2 \quad (18)$$

Curtosis

Mide la forma de la distribución de los retornos. Una curtosis elevada indica la presencia de colas pesadas, lo que sugiere mayor probabilidad de eventos extremos.

$$\text{Kurtosis} = \frac{1}{N} \sum_{i=1}^N \left(\frac{r_i - \bar{r}}{\sigma} \right)^4 \quad (19)$$

5.7. Límites y posibles líneas de mejora

Durante el desarrollo del trabajo se han identificado ciertas limitaciones que conviene tener en cuenta y que podrían abordarse en futuras investigaciones.

En primer lugar, la selección de activos se ha centrado en un número reducido de empresas, lo que simplifica el problema, pero limita la representatividad del mercado global. Además, los modelos se han aplicado sobre un único mercado (IBEX 35), por lo que los resultados podrían variar en otros contextos geográficos o sectores.

Por otro lado, en el caso del algoritmo genético, las configuraciones de parámetros como el tamaño de la población, el número de generaciones o la tasa de mutación, se han fijado de forma experimental, dejando margen para una posible optimización más exhaustiva de dichos hiperparámetros.

Finalmente, aunque se han incorporado métricas adicionales como el CVar o la curtosis para la evaluación de las carteras, no se han considerado otros factores relevantes como los costes de transacción, la liquidez de los activos o algunas restricciones regulatorias, que podrían incorporarse en futuros trabajos para hacer modelos aún más realistas.

6. Discusión de resultados

6.1. Análisis *in-sample*

En primer lugar, se realizará un análisis *in-sample*, o, lo que es lo mismo, una evaluación de las carteras que ofrecen los modelos utilizando los mismos datos históricos con los que han sido optimizadas.

Este enfoque nos permitirá observar como se comportan los modelos cuando disponen de la información completa y conocida del periodo a analizar. Aunque este escenario no es representativo de un entorno realista, ya que en la práctica los inversores no disponen de información futura, este análisis nos resultará útil como referencia inicial, para poder detectar posibles problemas de sobreajuste y poder comparar la capacidad de optimización que posee cada modelo bajo unas condiciones ideales.

Modelo clásico

En la Tabla 1, se puede observar la asignación de pesos óptima que ha ofrecido el modelo clásico de Markowitz en un escenario *in-sample*, en el año 2015.

Tabla 1. Asignación de pesos del modelo Markowitz

SAN.MC	BBVA.MC	ITX.MC	IBE.MC	REP.MC	TEF.MC	ACS.MC	FER.MC	GRF.MC	AMS.MC
0,00%	5,89%	0,00%	55,00%	14,87%	0,00%	24,25%	0,00%	0,00%	0,00%

Fuente: Elaboración propia.

Puede observarse cómo el modelo concentra la mayor parte de la inversión en IBE.MC, seguido de ACS.MC y REP.MC, mientras que asigna pesos nulos o muy bajos al resto de los activos. Esta distribución refleja las combinaciones de activos que el modelo considera más eficientes en función del equilibrio entre rentabilidad y riesgo según el modelo de Markowitz.

En la Tabla 2 se muestran los resultados que se obtienen con esta cartera.

Tabla 2. Evaluación in-sample de la cartera ofrecida por el modelo Markowitz

Medidas de evaluación	
Rentabilidad	30,68%
Volatilidad	20%
Ratio Sharpe	1,3839
CVar 95%	2,7%
Índice de Herfindahl	39%

Fuente: Elaboración propia

El principal punto a favor del modelo de Markowitz en este tipo de análisis es que trabaja con datos que ya se conocen por lo que puede encontrar la combinación óptima de activos ajustada exactamente al comportamiento pasado del mercado. Por ello, los resultados se pueden considerar los ideales para ese año.

En este contexto, el modelo bajo una volatilidad máxima del 20%, ha alcanzado una rentabilidad del 30,68%. Ambos valores se pueden resumir con la ratio de Sharpe, que es 1,38, lo que indica que la rentabilidad obtenida compensa de forma razonable el riesgo asumido, dado que, por cada unidad de riesgo, se obtiene más de una unidad de rentabilidad adicional.

Por otra parte, la cartera del modelo clásico ha obtenido un CVar (al 95%) de 2,7%, lo que quiere decir que, en el 5% de los peores escenarios diarios, las pérdidas medias no superarían dicho porcentaje.

Por último, el índice de Herfindahl, refleja el nivel de concentración que existe en la cartera. Un valor del 39%, refleja una concentración bastante alta en la cartera que ya hemos comentado en la Tabla 1.

Modelo avanzado

En la Tabla 3, observamos la asignación de pesos óptima que ofrece el modelo basado en el algoritmo genético multiobjetivo en el escenario *in-sample*.

Tabla 3. Asignación de pesos del algoritmo genético multiobjetivo

SAN.MC	BBVA.MC	ITX.MC	IBE.MC	REP.MC	TEF.MC	ACS.MC	FER.MC	GRF.MC	AMS.MC
0,00%	15,38%	0,02%	40,62%	3,04%	40,75%	0,04%	0,00%	0,00%	0,15%

Fuente: Elaboración propia.

Se puede observar que la solución obtenida difiere de la que ofrece el modelo de Markowitz, ya que, mientras el modelo clásico optimiza directamente una única solución sobre los datos conocidos, este modelo explora muchas otras posibles combinaciones.

Como resultado, el modelo basado en el algoritmo genético ha alcanzado una asignación con una fuerte concentración en IBE.MC y TEF.MC, ya que entre los dos activos acumulan más del 80% del peso de la cartera.

En la tabla 4, se muestran los resultados que ofrece esta asignación de pesos.

Tabla 4. Evaluación in-sample de la cartera ofrecida por el algoritmo genético multiobjetivo

Medidas de evaluación	
Rentabilidad	29,45%
Volatilidad	19,16%
Ratio Sharpe	1,380
CVar 95%	2,62%
Índice de Herfindahl	31,64%

Fuente: Elaboración propia.

Es razonable que el modelo avanzado no alcance los niveles de rentabilidad del modelo de Markowitz en un análisis *in-sample*. El modelo clásico, al resolver de forma exacta un problema de optimización convexa sobre datos conocidos, obtiene el punto óptimo global que maximiza la rentabilidad para el nivel máximo de volatilidad definido. Por el contrario, un algoritmo genético, al tratarse de un método heurístico, no persigue necesariamente ese óptimo matemático exacto, sino que explora el espacio de soluciones buscando combinaciones eficientes mediante procesos de selección, cruce y mutación.

A pesar de esto, en la Tabla 4, observamos que el algoritmo genético ha conseguido prácticamente igualar el Sharpe ratio del modelo de Markowitz. Aunque no alcanza la máxima rentabilidad, que ofrece el modelo clásico, ofrece otra solución competitiva, que además presenta una distribución de pesos distinta. Esta solución se ha obtenido gracias a la capacidad de exploración de soluciones que tiene este modelo.

Algo que podemos observar, es que ambos modelos han presentado unos niveles de volatilidad distintos. Esto ocurre porque, a pesar de que ambos tienen exactamente la misma restricción de volatilidad máxima, el modelo de Markowitz siempre tiende a aprovechar todo el riesgo permitido para maximizar la rentabilidad (sería poco común que una cartera de menor riesgo fuera más rentable que una de mayor riesgo). Esto no sucede con modelos heurísticos de varios objetivos, ya que, al explorar un amplio


abanico de soluciones basadas en diversos objetivos, la rentabilidad ya no es lo único que se tendrá en cuenta, permitiendo que se puedan construir muchos tipos diferentes de soluciones que no alcancen necesariamente el máximo de volatilidad permitido.

Comparación entre ambos enfoques

En la Figura 7, se ha representado gráficamente la posición que ocupan ambas soluciones sobre la frontera eficiente. En este gráfico lograremos visualizar de forma más clara las diferencias en términos de rentabilidad y riesgo entre el modelo clásico y el modelo avanzado.

Según la teoría, la cartera que ofrece el modelo clásico de Markowitz debería situarse justo sobre un punto de la curva, mientras que el algoritmo genético podría situarse por debajo ya que no tiene porque encontrar la mejor solución.

Figura 7. Representación de las carteras sobre la frontera eficiente



Fuente: Elaboración propia

Tal y como se puede observar en la Figura 7, la cartera que ofrece el modelo clásico se sitúa sobre la frontera eficiente, cumpliendo con los principios de este modelo. La solución respeta el objetivo de maximizar la rentabilidad para el nivel máximo de volatilidad establecido, obteniendo así una combinación de activos que, según este modelo, no puede mejorarse si no se asume un mayor nivel de riesgo.

Por su parte, la solución que ha generado el modelo basado en el algoritmo genético queda ligeramente por debajo de la frontera. Este resultado es coherente con su naturaleza heurística.


6.2. Análisis *out-of-sample*

Una vez analizado el comportamiento de ambos modelos sobre datos conocidos, se procede a evaluar su capacidad de generalización mediante un análisis *out-of-sample*. Para ello, los modelos serán entrenados empleando datos históricos de los precios de los activos para los años 2012, 2013 y 2014, y posteriormente se aplicarán las soluciones obtenidas a un año 'no visto' (2015) que actuará como periodo de prueba. Mediante este tipo de análisis podremos observar el grado de sobreajuste de cada modelo y se podrá analizar su desempeño en datos no conocidos, simulando así un escenario más próximo a la que se enfrentaría un inversor en la práctica.

Adicionalmente, en este análisis se incorporará un *benchmark*, representado por la evolución general del IBEX 35 durante el mismo periodo de prueba, lo que permitirá contextualizar los resultados obtenidos por los dos modelos en comparación con el comportamiento real del mercado en ese año.

En la figura 8, se observa la evolución de las rentabilidades acumuladas de las dos carteras optimizadas por los modelos y la rentabilidad del *benchmark*.

Figura 8. Evolución de la rentabilidad de las carteras y del mercado en 2015



Fuente: elaboración propia.

Podemos observar que, en cuanto a rentabilidad, la cartera que ofrece el AG Multiobjetivo destaca con el mejor desempeño, seguida de la cartera que ofrece el modelo de Markowitz, que también crece bastante, aunque se quede un poco atrás. No obstante, el IBEX 35 tiene, con bastante diferencia, el peor resultado.

Si hablamos en términos de riesgo, el IBEX 35 parece ofrecer los resultados más inestables, ya que en la figura se observan altibajos más marcados, lo que indica mayor volatilidad. Por otro lado, las carteras que se obtiene con los dos modelos parece que se mueven de forma más estable, aunque la que ofrece el modelo avanzado parece manejar aún mejor las fluctuaciones, ofreciendo un poco más de suavidad en su trayectoria.

En la Tabla 5, se observan los resultados obtenidos por los dos modelos y por el *benchmark*.

Tabla 5. Comparación de los resultados out-of-sample

Modelo	Rentabilidad	Volatilidad	Ratio Sharpe	CVar 95%	Índice de Herfindahl	Kurtosis
Markowitz	25,9%	23%	0.99	3,31%	92,94%	6,3
AG	28,9%	19,29%	1,34	2,68%	31,57%	0.41
IBEX 35	-4,68%	21,75%	-0.24			

Fuente: elaboración propia.


En el análisis *out-of-sample* se observa un cambio importante respecto al comportamiento *in-sample*. El modelo avanzado obtiene una rentabilidad superior al modelo de Markowitz (28,9 frente a 25,9%), además de mejorar la volatilidad (19,29% frente al 23%), lo que se traduce en un Sharpe ratio sensiblemente mejor (1,34 frente a 0,9932). Estos resultados confirman que el algoritmo genético, al no ajustarse de forma tan estricta a los datos de entrenamiento, muestra una mayor capacidad de generalización al aplicarse sobre datos no vistos. Estos resultados verifican lo previamente analizado en la figura 8.

Por otra parte, el AG presenta un mejor comportamiento en términos de riesgo extremo, reduciendo el CVaR al 95% hasta el 2,68% frente al 3,31% de Markowitz. También logra una mayor diversificación (Herfindahl de 31,31% frente al 92,94% del modelo clásico), lo cual confirma su capacidad para repartir la inversión de forma más equilibrada. Por su parte, el *benchmark* del IBEX 35 obtiene un resultado claramente inferior, con una

rentabilidad negativa y un Sharpe ratio negativo, lo que pone en valor la eficiencia de ambos modelos frente al mercado en el año analizado.

Por otro lado, observamos una curtosis muy elevada en el modelo de Markowitz, esto se debe a que el modelo parte de la asunción implícita de normalidad en las rentabilidades, lo que le permite optimizar únicamente en función de la media y la varianza. No obstante, en la práctica las rentabilidades suelen presentar colas más pesadas y curtosis elevada. En la figura 9 se observa una comparación entre la distribución que asume el modelo clásico y la distribución real de las rentabilidades.

Figura 9. Análisis de la distribución de rentabilidades de la cartera ofrecida por el modelo Markowitz en 2015



Fuente: elaboración propia.

En el histograma de la izquierda se observa que, aunque la distribución de rentabilidades diarias de la cartera de Markowitz presenta cierta similitud con la campana de Gauss teórica (curva roja), se aprecia una mayor concentración de valores en torno a la media y la presencia de algunos valores extremos, lo que indica una curtosis superior a la normal.

El gráfico Q-Q de la derecha confirma este comportamiento: la mayor parte de los puntos siguen aproximadamente la línea de referencia de la normalidad, pero los valores de las colas (tanto positivas como negativas) se desvían de forma notable, evidenciando la existencia de eventos extremos que no encajan con la hipótesis de normalidad perfecta que asume el modelo clásico.


6.3. Análisis en escenario de crisis

Una vez evaluados los modelos en escenarios *in-sample* y *out-of-sample*, se procede ahora a analizar su comportamiento bajo un contexto de alta inestabilidad financiera. Para ello, los modelos son entrenados con los datos correspondientes al año 2019 y posteriormente aplicados sobre el periodo marzo-abril de 2020, coincidiendo con el estallido de la crisis provocada por la pandemia global de la COVID-19. Este planteamiento permite analizar la capacidad de cada modelo para adaptarse a entornos caracterizados por una fuerte volatilidad y la aparición de eventos extremos.

Adicionalmente, se incorpora de nuevo el IBEX 35 como *benchmark* de referencia, lo que permite comparar los resultados obtenidos por ambos modelos frente al comportamiento real del mercado español durante esta fase de crisis.

En la Figura 10 se muestra la evolución de las rentabilidades acumuladas para cada modelo y para el IBEX 35 en el periodo analizado.

Figura 10. Evolución de la rentabilidad de las carteras y del mercado en la crisis del COVID-19



Fuente: elaboración propia.

Tras un inicio similar, ambos modelos experimentan caídas pronunciadas en las primeras semanas, coincidiendo con el estallido de la crisis sanitaria. Sin embargo, se aprecia que el modelo avanzado logra recuperarse de forma más rápida y sostenida, obteniendo el mejor comportamiento en términos de rentabilidad al final del periodo. El

modelo de Markowitz también consigue una cierta recuperación, aunque de forma más contenida. En contraste, el IBEX 35 mantiene un peor desempeño, con una recuperación mucho más limitada. En términos de volatilidad, se observan oscilaciones marcadas en todos los casos, propias de un entorno de crisis, aunque el modelo avanzado parece manejar mejor la estabilidad de la cartera en la fase posterior a la caída inicial.

En la tabla 6, se observa la comparación de los resultados obtenidos por ambos modelos y por el *benchmark* en este escenario de crisis.

Tabla 6. Comparación de los resultados en el COVID-19

Modelo	Rentabilidad	Volatilidad	Ratio Sharpe	CVaR 95%	Índice de Herfindahl	Kurtosis
Markowitz	-4,9%	74,46%	-0.698	11,8%	100%	0,229
AG	2,4%	51,58%	0,41	8,43%	52,2%	1,553
IBEX 35	-1,15%	62,51%	-1,846			

Fuente: elaboración propia.

Los resultados obtenidos durante la crisis del COVID reflejan de forma clara el distinto comportamiento de ambos modelos bajo un escenario de alta volatilidad. Como ya se observaba en la evolución de las rentabilidades acumuladas, el algoritmo genético consigue gestionar mejor el entorno de incertidumbre, obteniendo una rentabilidad positiva del 2,4%, frente a las pérdidas del 4,9% del modelo de Markowitz. Además, el AG lo hace asumiendo un nivel de volatilidad claramente inferior, logrando reducir el riesgo en un contexto especialmente adverso.

El *benchmark* del IBEX 35 muestra también un resultado negativo, incluso peor que el de Markowitz, con pérdidas superiores al 1% y el Sharpe ratio más bajo de los tres modelos. Esto refuerza el buen desempeño relativo del algoritmo genético en comparación tanto con el modelo clásico como con el propio mercado.

En términos de riesgo extremo, el AG vuelve a mostrar una mejor protección ante pérdidas severas, con un CVaR menor, mientras que el Markowitz, como ya se observó anteriormente, presenta mayores pérdidas extremas como consecuencia de su elevada concentración (índice de Herfindahl del 100%). Este patrón coincide con lo analizado previamente: el algoritmo genético, al explorar un mayor número de combinaciones y considerar medidas adicionales de riesgo, consigue soluciones más equilibradas, especialmente en contextos donde los supuestos de normalidad de Markowitz dejan de cumplirse.


6.4. Análisis en escenario de recuperación de una crisis

Una vez analizado el comportamiento de los modelos durante la fase de crisis, se procede ahora a evaluar su desempeño en un contexto de recuperación económica. En este caso, los modelos son entrenados utilizando los datos correspondientes al periodo 2018-2020, que incluye tanto fases de estabilidad como el propio año de crisis, y posteriormente aplicados sobre el año 2021, caracterizado por la recuperación de los mercados tras la fuerte inestabilidad de la pandemia. Este enfoque permite analizar la capacidad de los modelos para adaptarse a un entorno de recuperación progresiva, con menor incertidumbre que el periodo anterior pero todavía con cierta inestabilidad residual.

Al igual que en los escenarios anteriores, se incorpora el IBEX 35 como *benchmark* de referencia, lo que permite comparar el rendimiento de ambos modelos frente al comportamiento real del mercado español durante esta fase de recuperación.

En la Figura 11 se presenta la evolución de las rentabilidades acumuladas de ambos modelos y del IBEX 35 durante el año 2021.

Figura 11. Evolución de la rentabilidad de las carteras y del mercado en época de recuperación



Fuente: elaboración propia.

En este caso, se observa que el IBEX 35 presenta el mejor desempeño durante la mayor parte del periodo, reflejando la fuerte recuperación de los mercados tras la crisis. Por su

parte, el modelo avanzado consigue un comportamiento intermedio, manteniendo una evolución positiva pero más contenida respecto al índice. El modelo de Markowitz, en cambio, muestra un desempeño más irregular, con mayores oscilaciones a lo largo del año y una rentabilidad final más baja. Aunque la volatilidad sigue presente en todos los casos, el algoritmo genético vuelve a mostrar una trayectoria algo más estable que la del modelo clásico, especialmente en los momentos de caídas intermedias.

En la tabla 7, se observa la comparación de los resultados obtenidos por ambos modelos y por el *benchmark* en este escenario de recuperación.

Tabla 7. Comparación de resultados en época de recuperación

Modelo	Rentabilidad	Volatilidad	Ratio Sharpe	CVaR 95%	Índice de Herfindahl	Kurtosis
Markowitz	-5,72%	17,86%	-0,488	2,62%	50%	2,192
AG	-0,86%	17,01%	-0,227	2,51%	25,47%	1,382
IBEX 35	8,55%	16,24%	0,495			

Fuente: elaboración propia.

Los resultados obtenidos durante la fase de recuperación reflejan lo ya observado en la evolución de las rentabilidades acumuladas. El IBEX 35 logra en este caso un desempeño claramente superior, con una rentabilidad positiva del 8,55%, superando a ambos modelos optimizados. Tanto el modelo de Markowitz como el algoritmo genético no logran en este escenario capturar la fuerte recuperación del mercado, cerrando el periodo con rentabilidades negativas, aunque el AG consigue limitar mejor las pérdidas (-0,86%) en comparación con el modelo clásico (-5,72%).

En términos de riesgo, los tres presentan niveles de volatilidad relativamente contenidos respecto a los escenarios anteriores, aunque nuevamente el algoritmo genético mantiene la volatilidad más baja. Los valores de Sharpe ratio refuerzan estas diferencias: mientras el IBEX 35 logra una ratio positiva, los dos modelos optimizados presentan valores negativos, reflejando su incapacidad para aprovechar el contexto de recuperación.

Por último, se observa que el AG vuelve a ofrecer una diversificación superior, con un menor índice de Herfindahl, y controla mejor los riesgos de cola, como refleja el CVaR y la kurtosis más reducida. Esto confirma nuevamente el patrón observado en los escenarios anteriores: aunque el modelo avanzado no siempre maximiza la rentabilidad, consigue soluciones más estables y equilibradas desde el punto de vista del riesgo total de la cartera.

7. Conclusiones

A lo largo de este trabajo se ha llevado a cabo un análisis exhaustivo de dos enfoques de gestión de carteras: el modelo clásico, basado en la teoría de media-varianza de Markowitz, y un modelo avanzado desarrollado mediante algoritmos genéticos multiobjetivo. Ambos métodos han sido evaluados bajo distintas circunstancias de mercado con el fin de observar su comportamiento, sus fortalezas y limitaciones, no solo en condiciones ideales, sino también en escenarios que representan desafíos reales para la toma de decisiones financieras.

En primer lugar, los resultados obtenidos en el análisis *in-sample* han permitido comprobar el buen funcionamiento del modelo de Markowitz en contextos ideales, donde la optimización se realiza directamente sobre datos conocidos. El modelo clásico, al partir de un problema matemático bien definido y convexo, es capaz de alcanzar soluciones globales óptimas, maximizando la rentabilidad para un nivel de riesgo establecido. Este resultado era previsible, ya que el modelo opera sobre el mismo conjunto de datos con los que ha sido calibrado. En este escenario, el algoritmo genético, aunque no iguala los niveles de rentabilidad de Markowitz, obtiene resultados razonablemente buenos y logra carteras viables que respetan las restricciones impuestas.

Posteriormente, al aplicar ambos modelos en escenarios *out-of-sample*, donde los datos utilizados para entrenar no corresponden al periodo de prueba, se ha podido observar la capacidad de generalización de cada enfoque. En este contexto, el algoritmo genético ha mostrado un mejor comportamiento, logrando superar en rentabilidad ajustada al riesgo (Sharpe) tanto al modelo clásico como al propio índice de referencia (IBEX 35). Esto sugiere que la capacidad exploratoria de los algoritmos evolutivos permite encontrar soluciones más robustas ante cambios de condiciones en el mercado, evitando en cierto modo el sobreajuste que puede sufrir el modelo clásico.

Cuando los modelos se han sometido a un escenario extremo como el estallido de la crisis de la COVID-19, las diferencias entre ambos enfoques se han vuelto más evidentes. El modelo de Markowitz, altamente dependiente de las estimaciones de parámetros históricos, ha ofrecido un desempeño más débil, mostrando altos niveles de volatilidad y caídas significativas. Por el contrario, el modelo basado en algoritmos genéticos ha sido capaz de adaptarse mejor a la inestabilidad, presentando menores pérdidas y un riesgo más controlado. Esta capacidad puede explicarse por la flexibilidad

de los algoritmos evolutivos a la hora de explorar un conjunto más amplio de soluciones, lo que favorece la resiliencia de las carteras ante eventos inesperados.

Finalmente, en la fase de recuperación tras la crisis, el comportamiento de ambos modelos refleja las dificultades que pueden presentar las herramientas de gestión en mercados que experimentan procesos de normalización y reestructuración. Aunque en este caso el *benchmark* superó en rentabilidad a ambos modelos, es destacable que las soluciones propuestas por el algoritmo genético mantuvieron una diversificación y un control de riesgo relativamente estables, mientras que el modelo de Markowitz volvió a mostrar cierta sensibilidad a las variaciones abruptas del mercado.

En conjunto, este trabajo pone de manifiesto que, si bien el modelo clásico de Markowitz sigue siendo una referencia teórica fundamental en la gestión de carteras, existen alternativas avanzadas como los algoritmos genéticos multiobjetivo que ofrecen ventajas interesantes, especialmente en entornos de incertidumbre y elevada volatilidad. La capacidad de estos últimos para adaptarse a distintas condiciones de mercado, gestionar múltiples criterios simultáneamente y generar carteras diversificadas, los posiciona como una herramienta complementaria muy valiosa para la toma de decisiones en la práctica financiera actual.

10. Declaración de uso de inteligencia artificial

Durante la elaboración de este Trabajo de Fin de Grado se ha recurrido al uso de inteligencia artificial como herramienta de apoyo en distintas fases del desarrollo. Concretamente, ha servido para generar ideas iniciales, organizar el esquema general del trabajo, localizar y contrastar algunas fuentes bibliográficas, y aportar asistencia en la redacción de los apartados teóricos y técnicos. Igualmente, la IA ha colaborado en el análisis e interpretación de los resultados, facilitando la explicación de tablas, gráficos y ciertos conceptos complejos, además de contribuir a la mejora del estilo y claridad de los textos.

La principal herramienta empleada ha sido ChatGPT (OpenAI, versión GPT-4o, 2025), siempre utilizada como complemento bajo la supervisión y criterio personal del autor.

El propósito de su incorporación ha sido facilitar la elaboración de un contenido más estructurado, preciso y comprensible, sin delegar en ningún momento la responsabilidad

del trabajo. Todas las decisiones metodológicas, cálculos, análisis y conclusiones reflejadas en el documento son fruto del trabajo y validación personal del autor.

El impacto de la IA se ha limitado a tareas de apoyo y revisión, sin intervenir en la toma de decisiones académicas ni en la obtención de los resultados finales, los cuales han sido completamente desarrollados y contrastados por el autor.

8. Bibliografía

- **Anagnostopoulos, K. P., & Mamanis, G. (2011).** An experimental evaluation of five multiobjective evolutionary algorithms. *Expert Systems with Applications*, 38(11), 14208–14217. <https://doi.org/10.1016/j.eswa.2011.05.042>
- **Bienstock, D. (1996).** Computational study of a family of mixed-integer quadratic programming problems. *Mathematical Programming*, 74(2), 121–140. <https://doi.org/10.1007/BF02592099>
- **Branke, J., Scheckenbach, B., Stein, M., Deb, K., & Schmeck, H. (2009).** Portfolio optimization with an envelope-based multi-objective evolutionary algorithm. *European Journal of Operational Research*, 199(3), 684–693. <https://doi.org/10.1016/j.ejor.2007.11.059>
- **Deb, K. (2001).** *Multi-objective optimization using evolutionary algorithms*. John Wiley & Sons.
- **Elton, E. J., Gruber, M. J., Brown, S. J., & Goetzmann, W. N. (2014).** *Modern portfolio theory and investment analysis* (9ª ed.). Wiley.
- **Fabozzi, F. J., Gupta, F., & Markowitz, H. M. (2002).** *The theory and practice of investment management*. John Wiley & Sons.
- **Guo, Q. (2022).** Application and limitations of the Markowitz mean-variance model in real financial markets. *Journal of Investment Strategies*. https://www.researchgate.net/publication/360497685_Review_of_Research_on_Markowitz_Model_in_Portfolios
- **Holland, J. H. (1975).** *Adaptation in Natural and Artificial Systems*. MIT Press. <https://mitpress.mit.edu/9780262581110/adaptation-in-natural-and-artificial-systems/>
- **Hwang, S., & Satchell, S. (2010).** How loss averse are investors in financial markets? *Journal of Asset Management*, 11(5), 365–379. <https://doi.org/10.1057/jam.2010.19>
- **Jobst, N. J., Horniman, M. D., Lucas, C. A., & Mitra, G. (2001).** Computational aspects of alternative portfolio selection models in the presence of discrete asset choice constraints. *Quantitative Finance*, 1(5), 489–501. <https://doi.org/10.1088/1469-7688/1/5/301>
- **Kshatriya, S., & Prasanna, P. K. (2018).** Genetic algorithm-based portfolio optimization with higher moments in global stock markets. *Journal of Risk*, 20(4), 1–26. <https://doi.org/10.21314/JOR.2018.380>
- **Levy, H., & Sarnat, M. (1994).** *Capital investment and financial decisions* (5ª ed.). Prentice Hall.
- **Lo, A. W. (2024, marzo 16).** *Harry Markowitz and the foundations of modern finance*. CEPR–VoxEU. <https://cepr.org/voxeu/columns/harry-markowitz-and-foundations-modern-finance>
- **Luis Ángel Hernández. (2022, 6 de julio).** ¿Qué es y cómo funciona el modelo de Markowitz? Teoría de la cartera y frontera eficiente. *Rankia*.

<https://www.rankia.com/blog/bolsa-desde-cero/3479118-que-como-functiona-modelo-markowitz-teoria-cartera-frontera-eficiente>

- **Markowitz, H. (1952).** Portfolio selection. *The Journal of Finance*, 7(1), 77–91.
<https://doi.org/10.2307/2975974>
- **Mitchell, M. (1998).** *An introduction to genetic algorithms*. MIT Press.
- **Mwamba, J. W., Mbucici, L. M., & Mba, J. C. (2025).** Multi-objective portfolio optimization: An application of the non-dominated sorting genetic algorithm III. *International Journal of Financial Studies*, 13(1), 15.
<https://doi.org/10.3390/ijfs13010015>
- **Sáez Martínez, A. (2023).** *Optimización de carteras mediante algoritmos evolutivos multiobjetivo* [Trabajo Fin de Máster, Universidad Politécnica de Cartagena]. Repositorio UPCT. <https://repositorio.upct.es/server/api/core/bitstreams/597eecd7-cfe5-443e-a8ec-dca3cc95db0c/content>
- **Saputra, R. S., Rahayu, A. F., & Suhaimi, N. B. A. (2024).** Historical development of portfolio theory. *ResearchGate*. <https://www.researchgate.net/publication/351398319>
- **Sharpe, W. F., Alexander, G. J., & Bailey, J. V. (1999).** *Investments* (6ª ed.). Prentice Hall.
- **Venegas-Flores, J. de J., Hernández-Ortiz, M., & Ortiz-Medica, I. (2024).** Innovación en la optimización de carteras mediante el uso de algoritmos genéticos para emprendimientos sostenibles en mercados volátiles. *Scientia et PRAXIS*, 4(8), 61–89. <https://dialnet.unirioja.es/servlet/articulo?codigo=9878877>
- **Wikipedia contributors. (s.f.).** Optimización multiobjetivo. *Wikipedia, la enciclopedia libre*. Recuperado el 23 de mayo de 2025, de https://es.wikipedia.org/wiki/Optimizaci%C3%B3n_multiobjetivo

9. Anexos

Acceso al código completo y resultados (Enlace Google Drive)

https://drive.google.com/drive/folders/1l4kwfdYBjWgTwfOF5pvfkvPcBg053iO9?usp=drive_link

